

KMData – Módulo de Coleta de Dados e Recomendação de Objetos Educacionais

Kleber José Araújo Galvão Filho

Resumo

A proposta para ingresso no Mestrado da UFAL trata da personalização da aprendizagem em Ambientes Virtuais de Aprendizagem (AVA), com foco no desenvolvimento de um módulo de recomendação de objetos educacionais. O objetivo é usar dados de interação dos estudantes para oferecer sugestões personalizadas, buscando otimizar o processo de aprendizagem e reduzir taxas de desistência. A metodologia envolve um estudo experimental com coleta de dados, modelagem do estudante e recomendação de recursos. Espera-se que o módulo melhore o desempenho e engajamento dos alunos, promovendo uma experiência de aprendizagem mais adaptada às suas necessidades.

Palavras-chave: inteligência aumentada, Ambientes Virtuais de Aprendizagem, recomendação.

1 Introdução

1.1 Contexto e Justificativa

A inteligência aumentada utiliza tecnologias avançadas para melhorar as capacidades cognitivas humanas, funcionando em colaboração com a inteligência humana para oferecer insights mais profundos e soluções mais eficazes. Essa combinação de habilidades tecnológicas e humanas pode gerar resultados inovadores e úteis, com potencial na educação. O

mercado global de inteligência aumentada foi avaliado em 14,74 bilhões de dólares em 2022 e deve crescer para cerca de 142,3 bilhões até 2032 (veja na Figura 1).



Figura 1: Tamanho, participação e tendências do mercado de inteligência aumentada (Precedence 2024)

Por outro lado, a personalização da aprendizagem é um desafio enfrentado por estudantes em ambientes virtuais de aprendizagem (AVA), tais como Moodle ¹, LMS Canva ², S-Partnert e T-Partnert (Holanda et al. 2022, Bittencourt et al. 2009). Com o aumento do número de estudantes em cursos online, é essencial que os AVAs ofereçam recomendações personalizadas para maximizar a eficácia educacional (Kopcha 2012). Esses ambientes coletam grandes volumes de dados sobre as interações dos estudantes, como acessos a materiais e participação em atividades. No entanto, utilizar esses dados para personalizar o ensino ainda é um desafio (Bittencourt et al. 2009).

¹ <<https://moodle.org/>>

² <<https://www.canva.com/>>

A personalização no contexto educacional é essencial para o sucesso dos estudantes. A falta de personalização pode aumentar as taxas de evasão, pois os estudantes se desmotivam quando o conteúdo não corresponde ao seu ritmo e estilo de aprendizagem (Kopcha 2012). Portanto, é cada vez mais necessário utilizar dados disponíveis para criar experiências de aprendizagem adaptativas e envolventes.

Sistemas de recomendação (SR) têm se mostrado promissores no contexto educacional, utilizando técnicas de mineração de dados para oferecer sugestões personalizadas. Esses sistemas analisam as interações dos estudantes com o AVA para identificar padrões e ajustar as recomendações de recursos educacionais em tempo real, promovendo uma aprendizagem mais direcionada e eficiente (Romero e Ventura 2016). O desenvolvimento de um módulo de recomendação com essas capacidades representa uma oportunidade para avançar em direção a um ensino mais personalizado.

O **problema** desta proposta é como melhor personalizar a experiência de aprendizagem em ambientes virtuais de ensino, onde a crescente diversidade de perfis e o aumento do número de estudantes dificultam a entrega de suporte pedagógico adequado. A ausência de personalização nos cursos online dificulta o acompanhamento do progresso individual dos estudantes, resultando em maior taxa de desistência e menor engajamento. Esse problema é agravado pela falta de mecanismos que utilizem os dados gerados pelas interações dos estudantes com o AVA, impedindo uma intervenção pedagógica mais oportuna.

O **objetivo** desta proposta é desenvolver e implementar um módulo de recomendação em um AVA que utilize dados de interação dos estudantes para oferecer sugestões personalizadas de objetos educacionais integrados com LLMs.

Alguns **objetivos específicos** são: A integração da recomendação textual com modelos de linguagem de grande escala (LLMs) proprietárias tais como chatGPT ou Claude³ ou preferencialmente com modelos open-source tais como LLaMA⁴, Mistral⁵ ou Phi3⁶. Além disso, a criação de *Modelo do Aluno* com Aprendizagem de máquina e métodos não supervisionados para clusterização de estudantes com o mesmo perfil.

A **proposta** é a integração de um módulo em um AVA que coleta dados de interação dos estudantes e recomenda objetos educacionais personalizados integrados com LLMs. A recomendação será baseada em um modelo adaptativo que considerará o perfil e o progresso do estudante, utilizando técnicas de mineração de dados educacionais e sistemas de recomendação.

2 Revisão da Literatura

As tecnologias de inteligência artificial têm revolucionado o campo da educação, especialmente no contexto de AVAs. Entre essas inovações, destacam-se os modelos de linguagem de grande escala e a tecnologia dos transformers, que têm permitido avanços significativos na personalização do aprendizado.

Os transformers avançaram o estado da arte em geração de texto, utilizando mecanismos de *atenção* que atribuem diferentes pesos às diversas partes da entrada (Vaswani et al. 2017). Essa abordagem proporciona um processamento mais eficiente e uma maior capacidade para lidar com textos longos e complexos. O que antes seria feito em três anos poderia ser processado em um mês. A partir desse e

³ <<https://www.anthropic.com/>>

⁴ <<https://llama.meta.com/>>

⁵ <<https://mistral.ai/>>

⁶ <<https://azure.microsoft.com/pt-br/products/phi-3>>

de outros avanços, os modelos de linguagem de grande escala (LLMs) foram amplamente difundidos, sendo utilizados em sistemas de recomendação em AVAs.

Outro exemplo é apresentado por [Kasneci et al. 2023](#) e [Ding et al. 2024](#). Eles exploraram a aplicação de LLMs em sistemas de recomendação educacional, destacando seu potencial para aprimorar a personalização do aprendizado em ambientes virtuais. Esses modelos permitem uma análise detalhada das interações dos alunos, adaptando os conteúdos de forma mais precisa às necessidades individuais. Essa integração mostrou-se eficaz em aumentar o engajamento e otimizar os resultados educacionais, ajustando as recomendações de forma contínua e personalizada conforme o progresso dos alunos.

Além disso, [Huang et al. 2023](#) discutem métodos de ajuste fino de LLMs para personalização do aprendizado, destacando técnicas como o ajuste completo do modelo e a destilação de conhecimento, que se mostram eficazes para adaptar LLMs a tarefas educacionais específicas. Essas estratégias permitem que os modelos ofereçam respostas mais precisas e contextualizadas. Métodos menos intensivos, como o ajuste de prompts, também são explorados por sua eficiência em modificar o contexto dos modelos sem alterar suas arquiteturas, sendo especialmente relevantes em ambientes educacionais que exigem personalização precisa e eficiente do conteúdo didático.

Em suma, a integração de LLMs e técnicas avançadas de mineração de dados em AVAs oferece um potencial significativo para a personalização do ensino, ajustando os conteúdos de forma contínua e eficiente às necessidades individuais dos alunos.

Por outro lado, ([Brito et al. 2019](#)) apresenta em seu artigo a aplicação de técnicas de mineração de dados para identificar padrões e classificar estudantes mais

propensos à evasão em um curso de Sistemas de Informação. A pesquisa utilizou algoritmos como K-Means e J48 para analisar dados acadêmicos e descobriu que fatores como reprovação em disciplinas-chave, ausência em projetos, e idade acima de 26 anos são indicadores significativos de evasão. Os resultados demonstraram alta precisão na identificação desses perfis, oferecendo insights importantes para intervenções educacionais preventivas.

3 Metodologia

A pesquisa proposta adota uma abordagem experimental, centrada na implementação e avaliação de um módulo de recomendação de AVA com LLM. A metodologia inclui uma análise qualitativa e quantitativa dos resultados, realizada por meio da observação e interpretação das interações dos estudantes com o sistema, além da coleta de feedbacks subjetivos por meio de entrevistas e questionários.

O caráter experimental da pesquisa será evidenciado pela aplicação do módulo em um ambiente controlado, permitindo a avaliação de seu impacto sobre o engajamento e desempenho dos estudantes. A análise dos dados coletados servirá para validar as hipóteses e ajustar o sistema para futuras implementações. Veja [Figura 2](#) alguns procedimentos que serão executados.

O módulo proposto funciona em três etapas principais:

1. **Coleta de Dados:** Através da captura de logs de interação dos estudantes no AVA, incluindo tempo de permanência, recursos acessados, e participação em atividades.
2. **Modelagem do Estudante:** Utilização de técnicas de mineração de dados para criar perfis detalhados dos estudantes, levando em conta seus comportamentos e desempenho

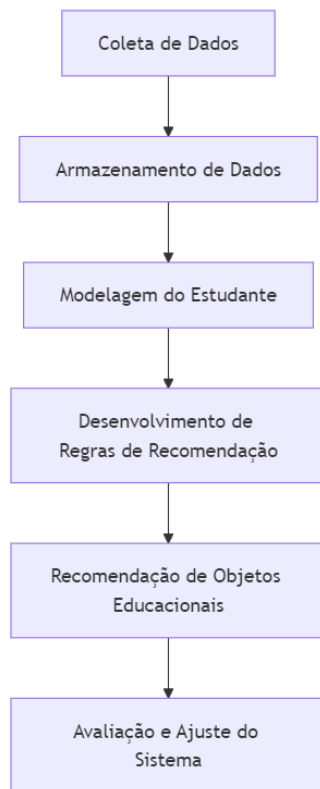


Figura 2: Procedimentos

3. **Recomendação de Objetos Educacionais com LLM:** Com base no modelo do estudante, o sistema recomenda objetos educacionais (vídeos, artigos, exercícios) que melhor se adequam ao seu perfil.

3.1 Amostra

Para a realização dos experimentos propostos, a amostra será composta por dois grupos de estudantes de graduação, totalizando mais ou menos 60 participantes. Cada grupo, com 30 estudantes, será selecionado a partir de turmas distintas dentro de um curso específico, com o uso de grupo-controle. Mesmo que a amostra seja por conveniência, ela poderá fornecer dados relevantes sobre o impacto do módulo no processo de aprendizagem, permitindo comparações entre as diferentes abordagens e a análise dos resultados obtidos.

3.2 Validação

Para avaliar a aceitação e a eficácia do módulo de recomendação proposto, será utilizado questionários com o Modelo de Aceitação de Tecnologia (TAM) (Davis, Bagozzi e Warshaw 1989). Este framework, amplamente empregado em estudos de adoção de tecnologia, permitirá analisar como os estudantes percebem a utilidade e a facilidade de uso do sistema, que são os principais construtos do modelo.

Outra proposta de validação, além do TAM é utilizar o o Cognitive Walkthrough Walkthrough, um método de inspeção que avalia a usabilidade analisando a rota que um usuário supostamente seguiria para atingir seu objetivo ao interagir com uma interface de sistema interativa (Polson et al. 1992). Além disso, podemos verificar a usabilidade e a resistência emocional com os questionários SUS, que fornece uma escala de Usabilidade de Sistemas, sendo um instrumento que mede a percepção dos usuários quanto à facilidade e eficácia da interação com um sistema específico (Brooke 2013); podemos também utilizar o SAM que é um instrumento de resposta emocional que utiliza imagens categorizadas em três dimensões: prazer, excitação e domínio (Bradley e Lang 1994). Por fim, podemos usar ainda o attraktdiff (Hassenzahl, Burmester e Koller 2003), para entender como os usuários avaliam a percepção e a avaliação subjetiva da qualidade, as qualidades pragmáticas, hedônicas e as consequências comportamentais e emocionais durante o uso da proposta.

3.3 Arquitetura

A Figura 3 apresenta um diagrama de sequência que ilustra o fluxo de interações entre os diferentes componentes do sistema de recomendação (SR) integrado ao

Moodle, com um exemplo do ChatGPT.

O SR busca os dados do aluno no Banco de Dados e envia os dados coletados para o módulo de recomendação que com o auxílio do ChatGPT retorna sugestões personalizadas baseadas nos dados fornecidos. Em seguida o SR processa e refina as recomendações, combinando as sugestões do ChatGPT com outras informações relevantes. Depois as recomendações finais são enviadas de volta ao Moodle que são personalizadas para o aluno. Além disso, O aluno interage com as recomendações (por exemplo, acessando recursos recomendados ou fornecendo feedback). Por fim, o feedback do aluno é enviado de volta ao SR através do Moodle e o SR atualiza o perfil do aluno no Banco de Dados com base nas interações e feedback.

O módulo de recomendação pode destacar áreas onde o estudante apresenta dificuldades, sugerindo materiais adicionais ou alternativas de estudo. Dessa forma, o sistema pode ajudar a mitigar possíveis deficiências antes que elas impactem significativamente o desempenho geral do estudante.

Além disso, o uso de um módulo de recomendação pode promover o engajamento contínuo dos estudantes no curso. Com recomendações personalizadas, os estudantes podem sentir que os recursos fornecidos são mais relevantes para o seu aprendizado, o que pode aumentar a motivação e a participação ativa nas atividades propostas pelo AVA. Esse engajamento aprimorado pode, a longo prazo, refletir-se em uma maior taxa de conclusão dos cursos oferecidos no AVA.

4 Resultados Esperados Referências

Espera-se que o módulo melhore o desempenho dos estudantes ao proporcionar uma experiência de aprendizagem mais personalizada e relevante. Além disso, a análise contínua dos dados permitirá ajustes no sistema, otimizando as recomendações.

A implementação de um módulo de recomendação que utiliza dados de interação dos estudantes com o AVA pode resultar em uma experiência de aprendizagem mais adaptada. Ao analisar os padrões de comportamento e participação dos estudantes, o sistema pode sugerir recursos educacionais que melhor se alinhem às necessidades individuais de cada usuário. Isso pode contribuir para um processo de aprendizagem mais eficiente, direcionando os estudantes para conteúdos diretamente relacionados ao seu progresso e desempenho.

Outro resultado esperado é a capacidade de identificar e atender a lacunas no conhecimento de forma mais eficaz.

Bittencourt et al. 2009 BITTENCOURT, I. I. et al. A computational model for developing semantic web-based educational systems. *Knowledge-Based Systems*, Elsevier, v. 22, n. 4, p. 302–315, 2009.

Bradley e Lang 1994 BRADLEY, M. M.; LANG, P. J. Measuring emotion: The self-assessment manikin and the semantic differential. *Journal of Behavior Therapy and Experimental Psychiatry*, v. 25, n. 1, p. 49–59, 1994.

Brito et al. 2019 BRITO, I. P. d. et al. Uso de mineração de dados educacionais para a classificação e identificação de perfis de evasão de graduandos em sistemas de informação. In: SOCIEDADE BRASILEIRA DE COMPUTAÇÃO (SBC). *Anais dos Workshops do VIII Congresso Brasileiro de Informática na Educação (WCBIE 2019)*. [S.l.], 2019. p. 159–168.

Brooke 2013 BROOKE, J. Sus: A retrospective. *Journal of Usability Studies*, v. 8, n. 2, p. 29–40, 2013.

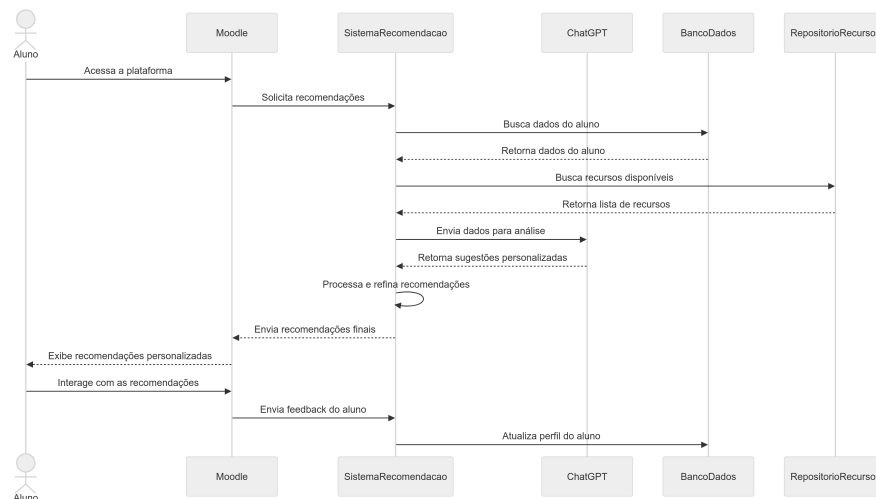


Figura 3: Diagrama de Sequência do principal caso de uso da Proposta, com a inclusão do chatGPT no Moodle.

Davis, Bagozzi e Warshaw 1989 DAVIS, F. D.; BAGOZZI, R.; WARSHAW, P. Technology acceptance model. *J Manag Sci*, Springer, v. 35, n. 8, p. 982–1003, 1989.

Ding et al. 2024 DING, Q. et al. Unraveling the landscape of large language models: a systematic review and future perspectives. *Journal of Electronic Business & Digital Economics*, v. 3, n. 1, p. 3–19, 2024.

Hassenzahl, Burmester e Koller 2003 HASSENZAHN, M.; BURMESTER, M.; KOLLER, F. Attrakdiff: Ein fragebogen zur messung wahrgenommener hedonischer und pragmatischer qualität. *Mensch & Computer 2003: Interaktion in Bewegung*, Springer, p. 187–196, 2003.

Holanda et al. 2022 HOLANDA, L. U. L. d. et al. R-partner: um sistema para apoio à realização de experimentos com design do tipo pré-teste e pós-teste em ambientes online de aprendizagem. Universidade Federal de Alagoas, 2022.

Huang et al. 2023 HUANG, X. et al. Trends, research issues and applications of artificial intelligence in language education. *Educational Society & Technology*, v. 26, n. 1, p. 112–131, 2023. Disponível em: <https://eric.ed.gov/?id=EJ1378438>.

Kasneci et al. 2023 KASNECI, E. et al. Chatgpt for good? on opportunities and

challenges of large language models for education. *Learning and Individual Differences*, v. 103, p. 102274, 2023.

Kopcha 2012 KOPCHA, T. J. Teachers' perceptions of the barriers to technology integration and practices with technology under situated professional development. *Computers & Education*, Elsevier, v. 59, n. 4, p. 1109–1121, 2012.

Polson et al. 1992 POLSON, P. G. et al. Cognitive walkthroughs: a method for theory-based evaluation of user interfaces. *International Journal of Man-Machine Studies*, v. 36, n. 5, p. 741–773, 1992.

Precedence 2024 PRECEDENCE, R. 2024. <https://www.precedenceresearch.com>.

Romero e Ventura 2016 ROMERO, C.; VENTURA, S. Educational data science in massive open online courses. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, Wiley Online Library, v. 6, n. 1, p. 12–21, 2016.

Vaswani et al. 2017 VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems*, v. 2017-Decem, n. Nips, p. 5999–6009, 2017. ISSN 10495258.